Projet étudiant NutriHFr — Apports nutritionnels des adultes en France (INCA 3)

Oct 21, 2026 · Alexandre Porchet

À partir de l'étude INCA 3 de l'Anses, ce projet décrit les apports nutritionnels de 2 121 adultes représentant environ 45 millions de Français de 18 à 79 ans : en moyenne 2 102 kcal/j, avec de fortes différences selon le sexe et l'âge.

1. Problématique

La question scientifique du projet est la suivante : **comment se caractérisent les apports nutritionnels des adultes vivant en France, comment varient-ils selon l'âge et le sexe, et quels aliments y contribuent le plus ?**

On cherche à décrire ce que les adultes mangent, ce que cela leur apporte en énergie et en nutriments, qui mange différemment, et d'où viennent les principaux nutriments. Six questions concrètes en découlent :

Question	Formulation	Résultat attendu
Q1 Énergie	Quelle est la distribution de l'apport énergétique journalier ?	moyenne pondérée, IC 95 %, percentiles
Q2 Sexe	Les apports diffèrent-ils entre hommes et femmes ?	moyennes par sexe et écarts
Q3 Âge	Comment évoluent-ils avec l'âge ?	moyennes par classe d'âge, régression
Q4 Densité	À énergie égale, qui a l'alimentation la plus riche en nutriments ?	apports pour 1 000 kcal
Q5 Contributeurs	Quels groupes d'aliments apportent le plus de protéines, calcium, fer, fibres et vitamine C ?	% de contribution par groupe
Q6 Variabilité	Les apports varient-ils beaucoup d'une personne à l'autre au sein d'un même groupe ?	médiane, quartiles, P5-P95

Le projet traite aussi les deux points méthodologiques demandés au niveau « attendu » : les pondérations d'enquête et la sous-déclaration des apports.

2. Données

2.1 Sources disponibles et choix

Source	Période	Méthode de recueil	Retenue ?
INCA 1	1998-1999	carnet de 7 jours	Non : méthode et nomenclature incompatibles
INCA 2	2006-2007	carnet de 7 jours consécutifs	Non : méthode différente d'INCA 3, comparaison déconseillée par l'Anses
INCA 3	2014-2015	2 ou 3 rappels de 24 h non consécutifs	**Oui**
NutriNet-Santé	depuis 2009	cohorte en ligne	Non : données non ouvertes

Le projet utilise uniquement **INCA 3**. C'est l'enquête la plus récente en accès libre, et ses fichiers contiennent à la fois les consommations détaillées, la composition de chaque aliment consommé et les apports calculés par l'Anses, ce qui permet de valider le pipeline.

2.2 Fiche d'identification

Rubrique	Contenu
Producteur	Anses
Source	data.gouv.fr, mise à jour du 28/01/2021
Documentation	notice utilisateurs INCA 3 (janvier 2021)
Population de l'enquête	5 855 individus de 0 à 79 ans, France métropolitaine
Population du projet	2 121 adultes de 18-79 ans ayant réalisé les rappels de 24 h (« Pop3 »)
Clé individu	`NOIND`
Confidentialité	données pseudonymisées, âge en classes

2.3 Volumétrie

Fichier	Lignes	Colonnes	Une ligne =
`description-indiv.csv`	5 855	185	un individu
`conso-compo-alim-vf-mad-datagouv2021.csv`	256 301 (149 392 pour nos adultes)	109	un aliment consommé, avec sa composition pour 100 g
`apports-nut-alim.csv`	4 114	108	un individu (apports calculés par l'Anses)

2.4 Composition nutritionnelle : pourquoi pas Ciqual ?

La consigne suggère de recalculer les apports à partir de la table Ciqual. Nous avons choisi d'utiliser la **composition fournie par l'Anses dans `conso-compo-alim`**, pour trois raisons :

- c'est la composition réellement utilisée pour INCA 3 ; la consigne rappelle d'ailleurs que cette table n'est pas la version la plus récente de Ciqual ;
- elle est appariée à **chaque ligne de consommation**, en tenant compte de la description précise de l'aliment (facettes : cuisson, ajout de matière grasse…), ce qu'un appariement code à code avec Ciqual ne permet pas : 611 codes aliments sur 2 857 ont plusieurs compositions, et ils couvrent la moitié des lignes de consommation ;
- elle permet une validation stricte : nos apports recalculés doivent être identiques à ceux publiés par l'Anses (section 4).

Conséquence : aucun mapping INCA → Ciqual n'est nécessaire, et la version de composition est celle de la mise à jour INCA 3 de janvier 2021. Utiliser Ciqual 2025 donnerait des apports différents, non comparables aux publications de l'Anses ; ce serait une piste d'extension.

3. Data engineering

3.1 Pipeline

Le pipeline est écrit en Python (pandas) et structuré en trois classes, dans `src/nutrihfr/pipeline.py`. Le script `scripts/run_pipeline.py` l'exécute de bout en bout en une commande, jusqu'à la base SQLite.

1. `ChargeurINCA3` lit les trois CSV et ne garde que les adultes Pop3 (pondération `pond_indiv_adu_pop3` non vide, classes d'âge 18-79 ans).

2. `ControleQualite` mesure la qualité des données selon 8 dimensions (section 4).
3. `CalculApports` calcule l'apport journalier de chaque individu.
4. `creer_base_sqlite` range les données dans le modèle relationnel défini dans `sql/schema.sql`.

3.2 Modèle relationnel

La base SQLite contient sept tables, reliées par des clés primaires et étrangères.

Table	Une ligne =	Clé primaire	Clés étrangères
`individus`	un adulte	`id_indiv`	
`journees`	un jour de rappel	(`id_indiv` , `no_jour`)	`individus`
`aliments`	un aliment de la nomenclature	`code_aliment`	
`nutriments`	un nutriment	`code_nutriment`	
`consommations`	un aliment consommé	`id_ligne`	`journees` , `aliments`
`composition`	une teneur pour 100 g	(`id_ligne` , `code_nutriment`)	`consommations` , `nutriments`
`apports`	un apport journalier calculé	(`id_indiv` , `code_nutriment`)	`individus` , `nutriments`

La composition est rattachée à la ligne de consommation, et non à l'aliment, car elle varie selon la description de l'aliment (section 2.4). La vérification `PRAGMA foreign_key_check` ne trouve aucune violation de clé.

3.3 Exploration et valeurs manquantes

Les 2 121 adultes ont déclaré 149 392 prises alimentaires, soit environ 24 par jour, portant sur 2 632 aliments différents. Les valeurs manquantes sont très rares et ne sont pas imputées :

- **poids corporel manquant** (5 adultes) : l'individu est gardé, mais exclu de l'analyse de sous-déclaration, qui en a besoin ;
- **composition manquante** (10 lignes : édulcorants, réglisse) : la ligne ne compte pas dans les apports, comme dans les calculs de l'Anses.

Aucune ligne n'est supprimée : il n'y a ni doublon, ni quantité nulle ou négative, ni valeur implausible.

3.4 Représentativité et pondérations

Les participants ne reflètent pas exactement la population : les femmes représentent 58 % de l'échantillon, contre environ la moitié des adultes en France. Deux pondérations corrigent ces écarts.

- **Pondération des individus** (`pond_indiv_adu_pop3`) : chaque adulte représente en moyenne 21 000 personnes, et l'ensemble environ 44,9 millions d'adultes. INCA 3 fournit trois jeux de poids selon le niveau de participation ; on prend celui des « participants CONSO », qui couvre exactement les 2 121 adultes ayant des rappels de 24 h. Toutes les moyennes et tous les percentiles sont pondérés. La taille d'échantillon effective de Kish, qui mesure la perte de précision due à la dispersion des poids, est calculée dans le notebook 02.
- **Pondération des jours** (`R24_pond`) : elle rééquilibre les jours de semaine (5/7) et de week-end (2/7) pour que les 2 ou 3 jours observés représentent une semaine type. Elle est déjà incluse dans la quantité `qte_conso_pond` .

3.5 Confidentialité (RGPD)

Les données sont pseudonymisées : un numéro remplace l'identité, et l'âge n'est diffusé qu'en classes. Elles restent des données de santé personnelles. Les fichiers ne sont donc pas publiés sur GitHub (dossier `data/` exclu par le `.gitignore`), et seuls des résultats agrégés sont présentés, y compris dans le dashboard.

3.6 Biais

Biais	Description	Traitement
Sélection (non-réponse)	les participants diffèrent des non-participants	pondérations d'enquête
Sous-déclaration	oubli ou minimisation de certaines prises	critère de Goldberg et analyse de sensibilité
Désirabilité sociale	sur-déclaration des aliments « sains »	cité en limite
Peu de jours observés	2-3 jours ne reflètent pas l'alimentation habituelle	décomposition de la variance (Q6)

4. Qualité des données et validation

4.1 Rapport qualité

Les données sont de très bonne qualité : seuls deux contrôles sur dix-sept signalent un point à vérifier, sans effet sur les résultats.

Dimension	Contrôle	Résultat
Complétude	poids corporel manquant	5 adultes
Complétude	lignes sans composition	10 lignes
Unicité	individus ou lignes en double	0
Validité	quantités nulles ou négatives ; compositions négatives ; sexe ou âge non codé	0
Cohérence	jours observés différents du nombre de rappels prévu ; adultes sans consommation	0
Intégrité référentielle	consommation d'un individu inconnu ; groupe d'aliments inconnu	0
Exactitude	quantité supérieure à 2 kg en une prise (maximum : 1,8 kg de bière) ; IMC hors [13 ; 70]	0
Homogénéité	énergie recalculée (Atwater) proche de l'énergie indiquée, à 10 % près	96,7 % des lignes
Traçabilité	lignes conservées / lues	149 392 / 149 392

Les 3,3 % d'écarts au contrôle d'Atwater s'expliquent par des composants absents de la formule (acides organiques, polyols). Le détail est dans `docs/rapport_qualite.md`.

4.2 Calcul des apports

Pour chaque individu, l'apport journalier d'un nutriment suit la méthode de l'Anses :

```
\text{apport journalier} = \frac{1}{\text{nombre de jours}} \sum_{\text{lignes}} \frac{\text{qte\_conso\_pond}}{100} \times \text{teneur pour 100 g}
```

4.3 Validation par l'Anses

C'est le test de validation suggéré par la consigne : comparer nos apports recalculés à ceux publiés par l'Anses dans `apports-nut-alim.csv`. Pour les 9 nutriments et les 2 121 adultes, **les deux sont identiques** (corrélation de 1, écart maximal inférieur à 0,001).

Cette validation montre aussi l'importance de la pondération des jours : avec `qte_conso` au lieu de `qte_conso_pond`, l'écart médian par individu va de 1 à 7 % selon les nutriments, l'alcool étant le plus touché.

5. Méthodes

Toutes les analyses portent sur les 2 121 adultes et sont pondérées par `pond_indiv_adu_pop3`. Elles sont réalisées dans le notebook 04, avec les fonctions de `src/nutrihfr/stats.py`.

Question	Indicateur	Méthode	Visualisation
Q1 Énergie	apport énergétique (kcal/j)	moyenne, IC 95 % et percentiles pondérés	histogramme pondéré par sexe
Q2 Sexe	apports par sexe	comparaison des moyennes pondérées et de leurs IC 95 %	tableau, boxplots
Q3 Âge	apports par classe d'âge	moyennes pondérées + régression linéaire pondérée `apport ~ sexe + classe d'âge`	moyennes et IC par classe
Q4 Densité	apport pour 1 000 kcal	rapport nutriment / énergie	barres
Q5 Contributeurs	% de l'apport venant de chaque groupe d'aliments	ratio des moyennes pondéré	barres empilées
Q6 Variabilité	médiane, quartiles, P5-P95 ; part de variance inter-individuelle	percentiles pondérés ; ANOVA à un facteur	violin plots
Sous-déclaration	apport énergétique / métabolisme de base	critère de Goldberg	histogramme

Hypothèses statistiques.

- Les intervalles de confiance à 95 % sont calculés par linéarisation (approximation normale). Ils utilisent les pondérations mais pas les strates ni les grappes du plan de sondage : ils sont donc un peu trop étroits.
- La régression suppose un effet additif du sexe et de l'âge ; la référence est une femme de 18-44 ans.
- Le **critère de Goldberg** compare l'apport énergétique au métabolisme de base estimé par les équations de Schofield (sexe, âge, poids). En dessous du seuil de Black (2000), environ 1,0 pour 3 jours et 0,96 pour 2 jours avec un niveau d'activité physique supposé de 1,55, l'apport déclaré est incompatible avec le maintien du poids. L'âge étant connu seulement en classes, on utilise le milieu de la classe (31, 55 ou 72 ans).
- **Q6 sur les femmes de 18-44 ans** : la consigne propose les femmes de 25-44 ans, mais INCA 3 ne diffuse que trois classes d'âge adultes (18-44, 45-64, 65-79 ans). On retient la classe la plus proche.

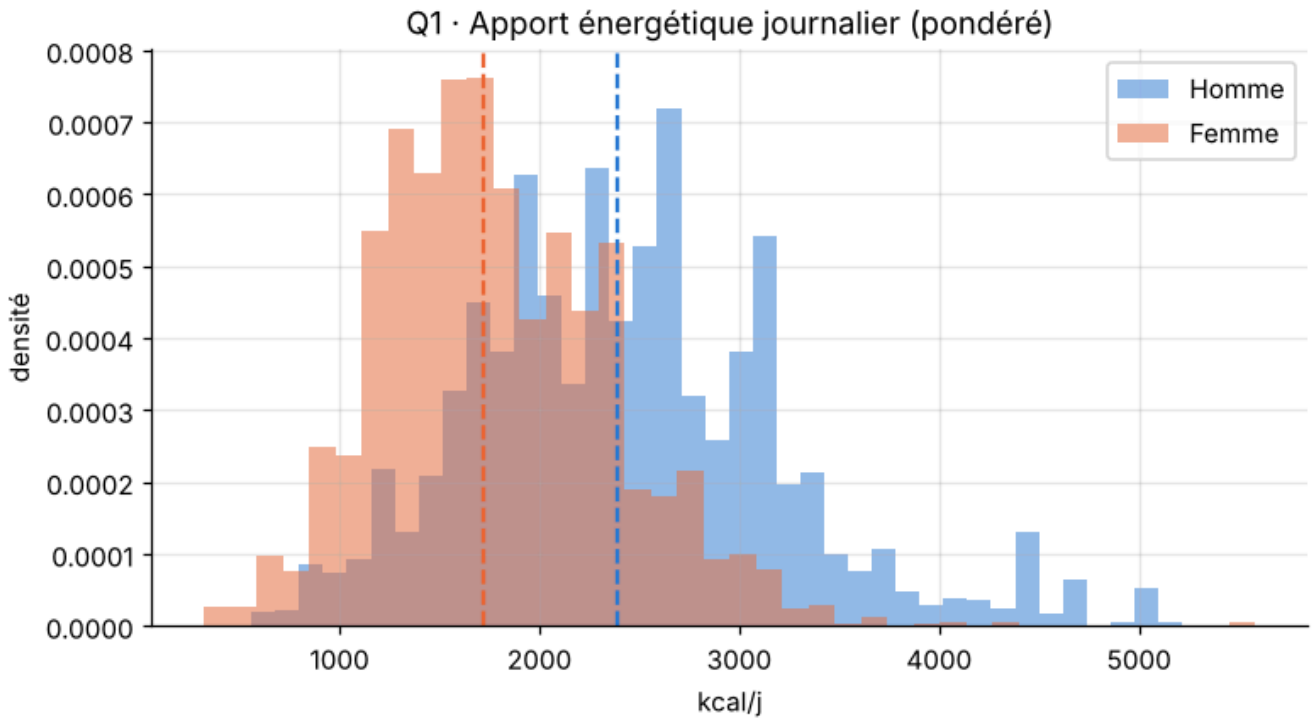
6. Résultats

Toutes les valeurs sont des moyennes pondérées (`pond_indiv_adu_pop3`) avec leur intervalle de confiance à 95 %. Effectifs : 2 121 adultes, dont 1 234 femmes et 887 hommes.

Q1 — Apport énergétique

Les adultes consomment en moyenne 2 102 kcal/j (IC 95 % : 2 048-2 157), et la moitié d'entre eux moins de 2 014 kcal/j.

	n	Moyenne (kcal/j)	IC 95 %	Médiane	P5 - P95
Ensemble	2 121	2 102	2 048 - 2 157	2 014	1 047 - 3 358
Femmes	1 234	1 787	1 738 - 1 836	1 723	942 - 2 783
Hommes	887	2 438	2 356 - 2 519	2 386	1 251 - 3 842



La distribution est légèrement étalée vers les fortes valeurs (moyenne supérieure à la médiane). Les apports très bas (P5 autour de 1 000 kcal/j) sont un premier signal de sous-déclaration.

Q2 — Différences entre hommes et femmes

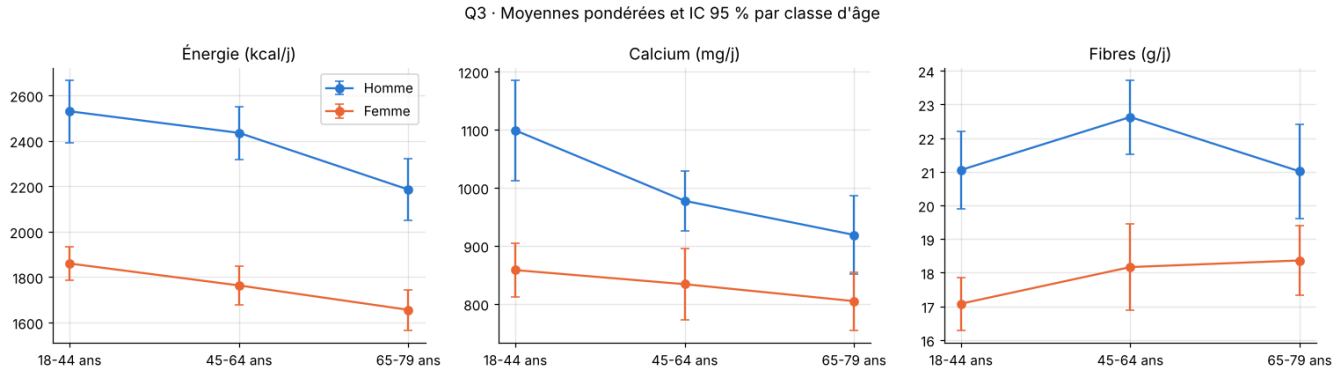
Les femmes ont des apports plus faibles que les hommes pour les 9 nutriments étudiés, et aucun intervalle de confiance ne se chevauche.

Nutriment	Femmes	Hommes	Écart F/H
Énergie (kcal/j)	1 787	2 438	-27 %
Protéines (g/j)	71,1	95,9	-26 %
Glucides (g/j)	204,6	277,4	-26 %
Lipides (g/j)	67,1	86,0	-22 %
Fibres (g/j)	17,7	21,6	-18 %
Alcool (g/j)	5,1	16,6	-70 %
Calcium (mg/j)	840	1 024	-18 %
Fer (mg/j)	8,9	12,2	-27 %
Vitamine C (mg/j)	85,5	95,9	-11 %

L'essentiel de l'écart vient de la quantité mangée : l'écart d'énergie (-27 %) est du même ordre que ceux des protéines ou des glucides. Les écarts plus faibles pour la vitamine C, les fibres et le calcium annoncent une alimentation plus dense chez les femmes (Q4).

Q3 — Évolution avec l'âge

L'apport énergétique diminue avec l'âge : à sexe égal, les 65-79 ans consomment 270 kcal/j de moins que les 18-44 ans (IC 95 % : 188-351).

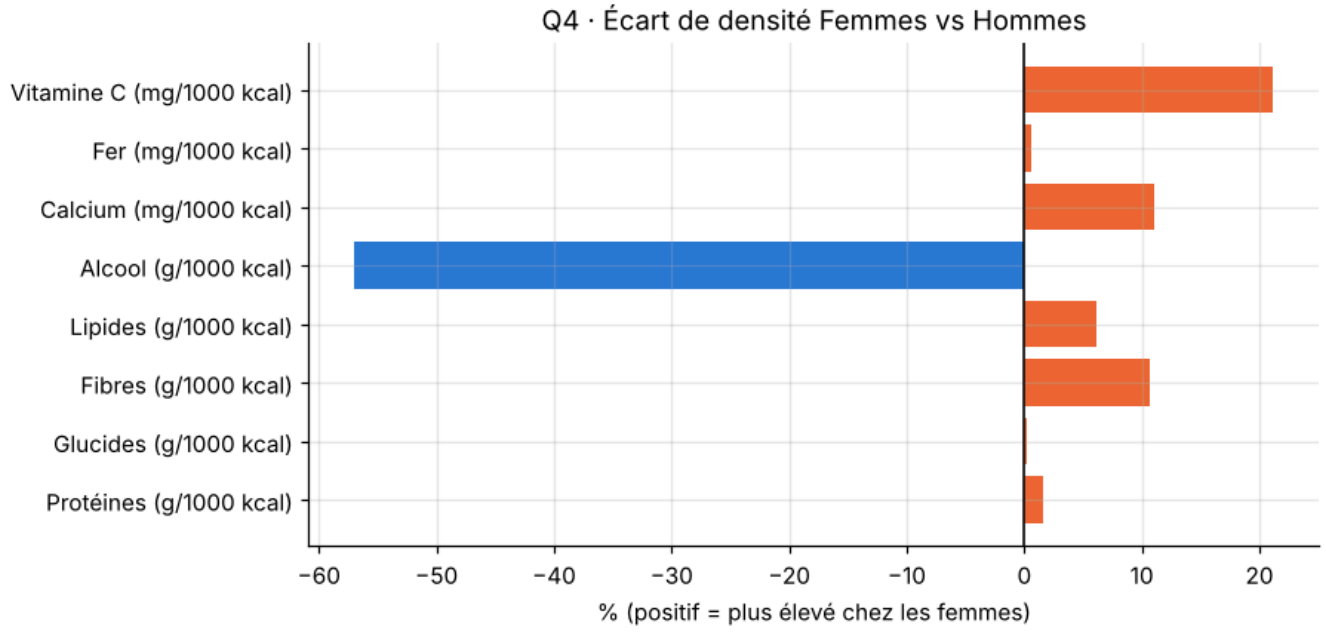


Régression pondérée (référence : femme de 18-44 ans)	Énergie (kcal/j)	Calcium (mg/j)	Vitamine C (mg/j)
Homme	+646 [588 ; 705]	+183 [149 ; 217]	+11 [6 ; 15]
45-64 ans	-96 [-161 ; -31]	-72 [-109 ; -35]	+9 [4 ; 14]
65-79 ans	-270 [-351 ; -188]	-114 [-161 ; -66]	+15 [8 ; 21]

Le calcium suit l'énergie et baisse avec l'âge, surtout chez les hommes (1 099 mg/j à 18-44 ans, 919 à 65-79 ans). À l'inverse, la vitamine C augmente avec l'âge, signe d'une consommation de fruits et légumes plus fréquente chez les plus âgés. Les protéines et les fibres varient peu.

Q4 — Densité nutritionnelle

À énergie égale, l'alimentation des femmes est plus riche que celle des hommes en vitamine C (+21 %), calcium (+11 %) et fibres (+11 %).

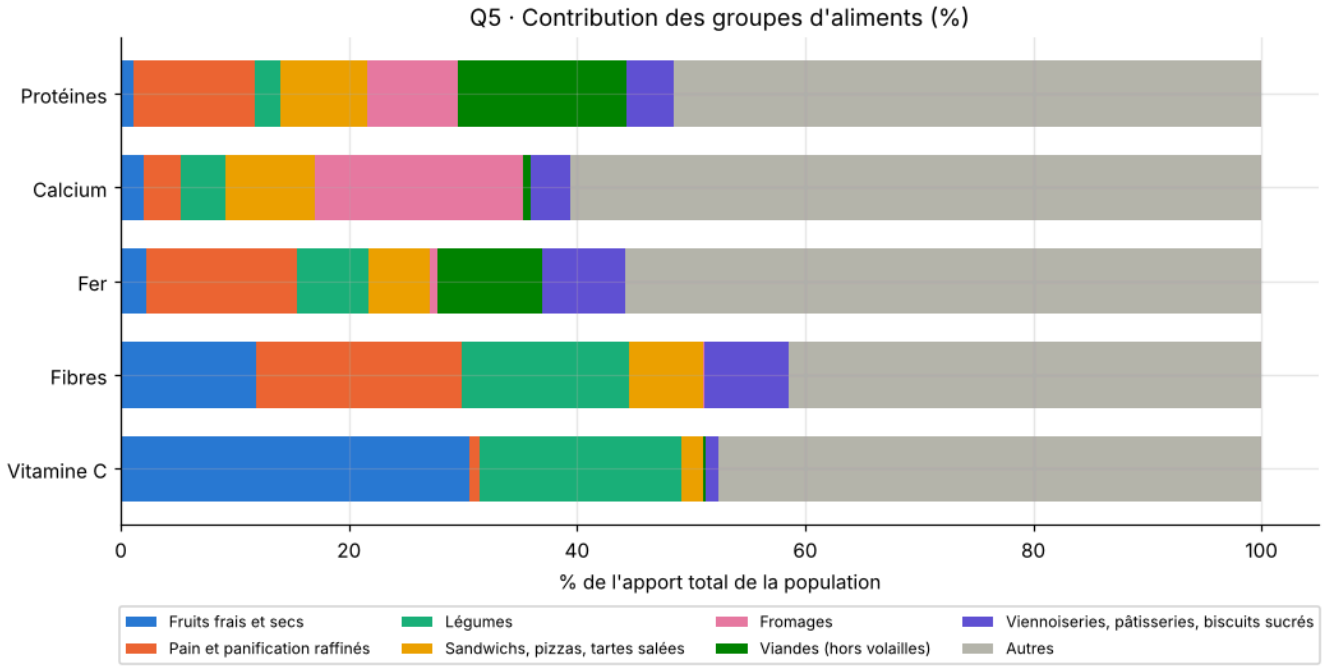


Rapporter les apports à 1 000 kcal neutralise le fait que les hommes mangent plus : les protéines, les glucides et le fer deviennent quasi identiques (écarts inférieurs à 2 %). La répartition de l'énergie est proche dans les deux sexes : environ 16 % de protéines, 45 % de glucides et 32 à 34 % de lipides ; l'alcool fournit 4,5 % de l'énergie chez les hommes contre 1,9 % chez les femmes.

Q5 — Principaux aliments contributeurs

Les produits laitiers apportent 38 % du calcium, et les fruits, jus et légumes 67 % de la vitamine C.

Nutriment	1er contributeur	2e	3e
Protéines	Viandes hors volailles (15 %)	Pain raffiné (11 %)	Volailles (8 %)
Calcium	Fromages (18 %)	Yaourts et fromages blancs (10 %)	Laits (10 %)
Fer	Pain raffiné (13 %)	Viandes hors volailles (9 %)	Viennoiseries, pâtisseries, biscuits (7 %)
Fibres	Pain raffiné (18 %)	Légumes (15 %)	Fruits (12 %)
Vitamine C	Fruits (31 %)	Jus de fruits et légumes (18 %)	Légumes (18 %)

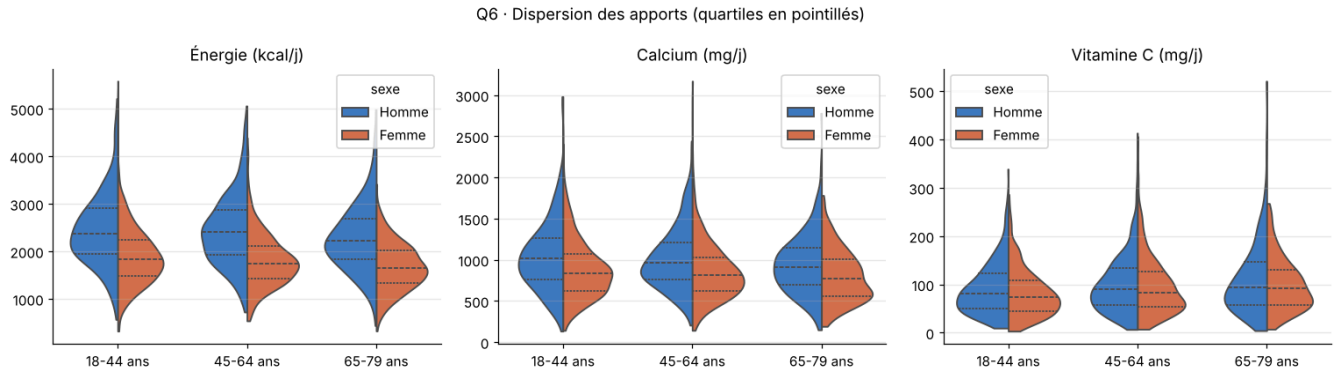


Les protéines et le fer viennent de sources très dispersées : les trois premiers groupes n'en apportent qu'environ un tiers. Le pain raffiné ressort comme contributeur majeur du fer et des fibres, non pour sa richesse, mais parce qu'il est consommé en grande quantité par presque tout le monde.

Q6 — Variabilité entre individus (femmes de 18-44 ans, n = 459)

Les apports varient fortement d'une femme à l'autre : pour le calcium, 90 % des femmes de 18-44 ans se situent entre 375 et 1 567 mg/j, pour une médiane de 809 mg/j.

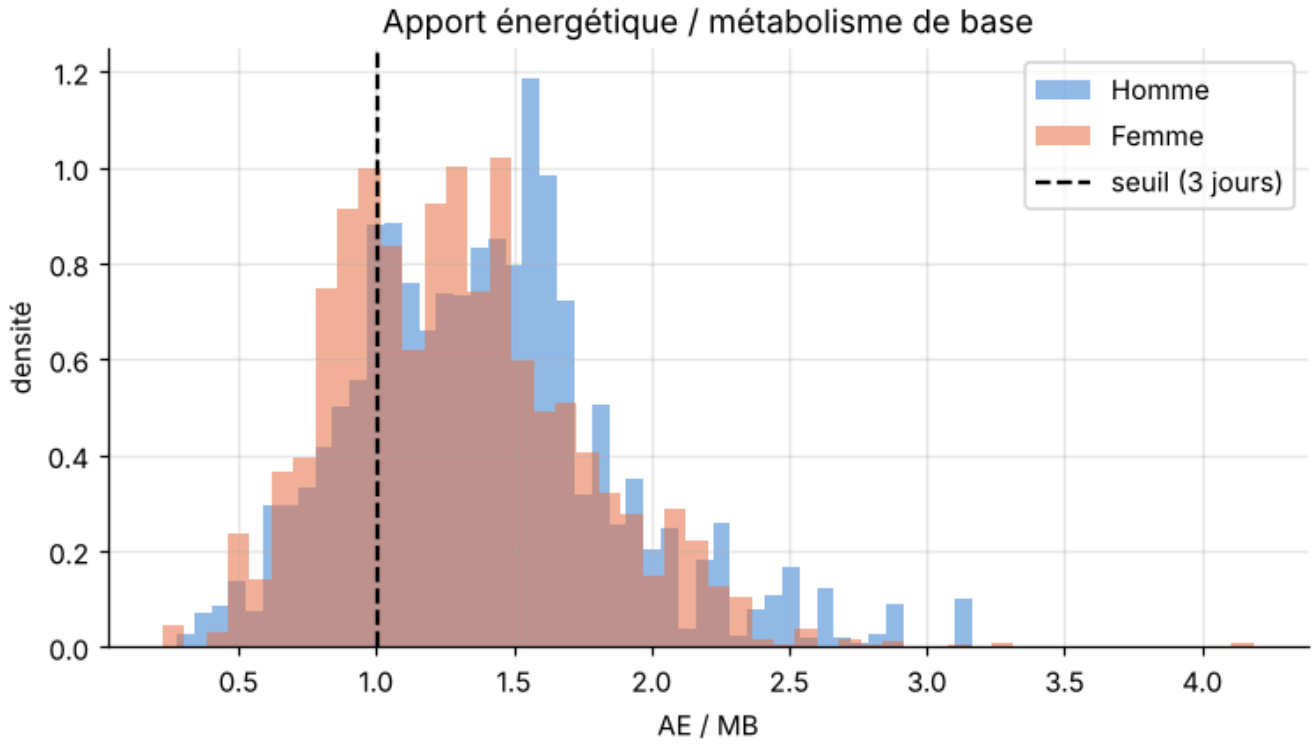
Nutriment	Moyenne	Médiane	P5 - P95	P25 - P75	Part de variance inter-individuelle
Énergie (kcal/j)	1 860	1 811	975 - 2 892	1 399 - 2 238	43 %
Protéines (g/j)	70,4	67,1	41,6 - 108,7	57,1 - 83,4	34 %
Fibres (g/j)	17,1	16,5	7,9 - 27,5	12,7 - 21,0	37 %
Calcium (mg/j)	858	809	375 - 1 567	592 - 1 042	40 %
Fer (mg/j)	9,1	8,8	4,4 - 14,8	6,8 - 10,9	23 %
Vitamine C (mg/j)	77,7	67,4	18,3 - 172,6	39,3 - 103,0	27 %



Une grande partie de cette dispersion vient des variations d'un jour à l'autre chez une même personne : seuls 23 à 43 % de la variance d'une journée reflètent de vraies différences entre femmes. Comme le rappelle la notice INCA 3, la moyenne et la médiane sont robustes, mais P5 est sous-estimé et P95 surévalué. Les nutriments épisodiques (vitamine C, fer, alcool) sont les plus touchés.

Sous-déclaration

Selon le critère de Goldberg, 25 % des adultes sous-déclarent probablement leur apport énergétique (IC 95 % : 22-28 %) : 30 % des femmes et 20 % des hommes.



Cette prévalence est élevée mais cohérente avec ce qu'on observe dans les enquêtes par rappel de 24 h. Elle dépend de l'hypothèse d'activité physique (PAL = 1,55) et de l'âge approché par le milieu de classe. Son effet sur les résultats est mesuré en section 7.

7. Discussion

7.1 Choix des métriques

- **Moyenne pondérée et IC 95 %** : c'est l'estimateur de la population française, comparable aux publications de l'Anses. La médiane et les percentiles complètent pour les distributions asymétriques (alcool, vitamine C).
- **Apport pour 1 000 kcal** : il sépare « manger plus » de « manger différemment ». Sans lui, Q2 conclurait seulement que les hommes mangent plus.
- **Ratio des moyennes pour les contributions** : il répond à la question de santé publique « d'où vient le calcium consommé par la population ? », et ses parts somment à 100 %. La moyenne des ratios donnerait le même poids à une personne qui consomme 200 mg de calcium et à une autre qui en consomme 2 000, et serait instable pour les petits consommateurs.
- **Critère de Goldberg** : c'est la méthode de référence pour repérer les apports énergétiques implausibles, et la seule applicable sans mesure de la dépense énergétique.

7.2 Validation et robustesse

La méthode est **validée** par la comparaison avec l'Anses : nos apports sont identiques aux siens pour tous les nutriments et tous les individus (section 4.3).

La **robustesse** est testée par deux analyses de sensibilité :

Nutriment	Tous (pondéré)	Sans sous-déclarants	Effet de l'exclusion	Non pondéré	Effet de la pondération
Énergie (kcal/j)	2 102	2 378	+13 %	2 057	-2 %
Protéines (g/j)	83,1	91,4	+10 %	81,1	-2 %
Fibres (g/j)	19,6	21,8	+11 %	19,8	+1 %
Calcium (mg/j)	929	1 021	+10 %	922	-1 %
Fer (mg/j)	10,5	11,7	+12 %	10,3	-2 %
Vitamine C (mg/j)	90,5	98,0	+8 %	95,4	+5 %

- Exclure les sous-déclarants augmente les apports moyens de 8 à 13 % (21 % pour l'alcool). Les **niveaux absolus** de Q1 à Q3 sont donc sensibles à la sous-déclaration et probablement sous-estimés. En revanche, les **comparaisons** (sexe, âge), les **densités** et les **parts de contribution** changent peu, car la sous-déclaration touche tous les nutriments à peu près de la même façon.

- La pondération modifie les moyennes de moins de 6 %, mais reste indispensable pour que les résultats représentent la population française et non l'échantillon.

7.3 Reproductibilité

- **Code versionné** avec Git et publié sur GitHub (sans les données).
- **Environnement** : `requirements.txt` (pandas, numpy, matplotlib, seaborn, Streamlit) et un environnement conda en Python 3.11.
- **Pipeline relançable** : `python scripts/run_pipeline.py` reconstruit tout depuis les fichiers bruts, sans intervention manuelle ; les notebooks 01 à 05 s'exécutent dans l'ordre.
- **Paramètres centralisés** dans `src/nutrihfr/config.py` : noms de fichiers, pondération, correspondances des nutriments et des groupes, tirées de la notice INCA 3.
- **Tests automatisés** : les 7 tests de l'annexe D, plus un test de validation contre l'Anses, sont regroupés dans le notebook `05_tests.ipynb`. Chaque test est une assertion : il arrête l'exécution en cas d'échec. Pour un projet de cette taille, un notebook a été préféré à pytest, parce qu'il montre le résultat de chaque test à côté de son explication. La contrepartie : les tests ne se lancent pas tout seuls à chaque modification du code, il faut ré-exécuter le notebook. Ils pourraient être transférés tels quels dans des fonctions `test_...` pour pytest. Les tests 3 et 7 portent sur la composition fournie par l'Anses, et non sur Ciqual (section 2.4).
- **Dashboard** : `streamlit run app/dashboard.py` permet d'explorer les résultats par nutriment, sexe et classe d'âge.

7.4 Traçabilité

Chaque fichier source est identifié (nom, URL, version du 28/01/2021). Aucune ligne n'est supprimée par le nettoyage, et la seule sélection (adultes Pop3) est documentée. Chaque résultat peut être relié à son lignage, comme ici :

```
Calcium moyen = 858 mg/j (IC 95 % : 812-905)
├── Population   : femmes, 18-44 ans (n = 459)
├── Source       : INCA 3 (Anses), conso-compo-alim + description-indiv
├── Composition  : fournie par l'Anses pour chaque ligne (pour 100 g)
├── Formule      : qte_conso_pond / 100 x calcium, somme / nombre de jours
├── Agrégation   : moyenne pondérée des apports individuels
├── Pondération  : pond_indiv_adu_pop3
└── Code         : commit Git (affiché dans le notebook 04)
```

7.5 Limites

- **Méthode de recueil** : 2 ou 3 rappels de 24 h donnent des apports *observés*, pas *habituels*. Les moyennes sont fiables, mais les percentiles extrêmes (Q6) sont élargis. Une modélisation de l'apport habituel (méthodes NCI ou SPADE) serait nécessaire pour estimer la part de la population sous un seuil de besoin.
- **Sous-déclaration** : environ un quart des adultes sous-déclarent probablement leur apport. Le critère de Goldberg ne repère que les cas extrêmes et dépend d'une hypothèse d'activité physique.
- **Âge en classes** : il impose la classe 18-44 ans pour Q6 et un âge approché pour le métabolisme de base.
- **Plan de sondage** : les strates et les grappes ne sont pas prises en compte, ce qui rend les IC un peu trop étroits.
- **Nomenclature et composition** : les résultats dépendent de la nomenclature INCA 3 (44 groupes) et de la composition utilisée par l'Anses. Ils ne sont pas directement comparables à un calcul fondé sur Ciqual 2025, ni à INCA 2 (méthode de recueil différente). Sans mapping vers Ciqual, la couverture du mapping n'est pas mesurée.

8. Conclusion

Ce projet a construit une chaîne de traitement complète et reproductible sur les données INCA 3, des fichiers bruts à une base SQLite, puis jusqu'aux analyses et au dashboard. Le calcul des apports est validé : il reproduit exactement les valeurs publiées par l'Anses.

Principaux enseignements :

- les adultes consomment en moyenne 2 102 kcal/j, avec un écart de 650 kcal/j entre hommes et femmes et une baisse avec l'âge ;
- à énergie égale, les femmes ont une alimentation plus riche en vitamine C, en calcium et en fibres ;
- le calcium vient surtout des produits laitiers, la vitamine C des fruits, jus et légumes, et les protéines et le fer de sources très variées ;
- environ un quart des adultes sous-déclarent probablement leur apport, ce qui conduit à sous-estimer les niveaux absolus, sans remettre en cause les comparaisons.

Pistes d'amélioration : modéliser l'apport habituel, tenir compte du plan de sondage complet pour les IC, et traiter les questions bonus (profils alimentaires par ACP et k-means, mapping vers Ciqual 2025).

Références

- Anses (2021). Données de consommations et habitudes alimentaires de l'étude INCA 3, data.gouv.fr, et notice utilisateurs associée (janvier 2021).
- Anses (2017). Étude individuelle nationale des consommations alimentaires 3 (INCA 3). Avis et rapport d'expertise collective.
- Black A.E. (2000). Critical evaluation of energy intake using the Goldberg cut-off for energy intake:basal metabolic rate. *International Journal of Obesity*, 24, 1119-1130.
- Schofield W.N. (1985). Predicting basal metabolic rate, new standards and review of previous work. *Human Nutrition: Clinical Nutrition*, 39C, 5-41.
- Règlement (UE) n° 1169/2011 concernant l'information des consommateurs sur les denrées alimentaires (coefficients de conversion énergétique).